



Desafio Técnico — Analista de Dados Pleno

Unifor · Diretoria de Tecnologia (DTec)

Prazo: 3 dias corridos

Dataset: Microdados ENADE 2023 (INEP)

A Diretoria de Tecnologia da Unifor está estruturando sua área de Dados. Este desafio simula, em escala reduzida, o tipo de problema que você vai encontrar por aqui: pegar uma fonte de dados bruta e transformá-la em algo confiável, bem modelado e que gere resposta para uma pergunta de negócio real.

Não esperamos uma solução perfeita. Esperamos ver **como você pensa, prioriza e explica as suas escolhas** — inclusive saber dizer "não fiz X por causa do prazo, mas faria assim".

O dataset

Vamos usar os **Microdados do ENADE 2023** (INEP/MEC) — dado público, educacional, do tipo que você vai encontrar no dia a dia aqui na Unifor.

Download oficial (baixe direto daqui, não fornecemos os arquivos):

https://download.inep.gov.br/microdados/microdados_enade_2023.zip

O pacote traz 32 arquivos `.txt` (delimitados por `;`) e uma pasta `1.LEIA-ME/` com o dicionário de variáveis e o manual do usuário — leia-os antes de começar a codar. Sério.

⚠ Uma regra do próprio INEP que você precisa respeitar

Por exigência de LGPD, o INEP embaralha cada um dos 32 arquivos por uma variável diferente. O manual afirma explicitamente:

"É possível agrupar os diferentes arquivos pelo código de curso (CO_CURSO). No entanto, não é possível agrupar as informações no nível de estudante, considerando que cada arquivo está ordenado por variáveis distintas."

Ou seja: **o único join válido entre os 32 arquivos é por CO_CURSO**, agregado a nível de curso. Juntar arquivos por posição de linha, ou tratar a linha N de um arquivo como "o mesmo aluno" da linha N de outro, é **errado e gera dados inventados** — mesmo que o pipeline rode sem erro. Explique como você tratou isso no README.

O ENADE só traz **códigos numéricos de IES (CO_IES)**, sem nome de instituição. Para a Pergunta 1 abaixo, cruze esse código com uma fonte pública complementar (ex.: **Cadastro e-MEC**, emec.mec.gov.br, ou **Microdados do Censo da Educação Superior**) para achar o código da Unifor.

As 3 perguntas de negócio

Sua camada **Gold** precisa ser modelada de forma que estas 3 perguntas sejam respondidas com **queries SQL diretas nela**. Documente/entregue a query (ou o modelo dbt) usada para cada resposta.

Q1 A Unifor está no ENADE 2023? Qual o código de IES dela (cite como você descobriu)? Quantos cursos ela ofertou, em quais áreas (CO_GRUPO) e em qual modalidade?

Q2 Presencial x EaD: a nota geral média (NT_GER) difere entre as modalidades Presencial e EaD?

Q3 Top 10 dos cursos da Unifor: liste os 10 cursos da Unifor com a maior nota geral média (NT_GER). Qual está no topo? Isso bate com o que a coordenação acadêmica esperaria (ex.: cursos de saúde tradicionais performando melhor)?

Curiosidades opcionais (contam ponto extra se você explorar alguma):

- Quem é a IES com a melhor nota do Brasil nas áreas em que a Unifor atua, e quão perto/longe ela está?
- Existe relação entre o perfil socioeconômico dos estudantes (ex.: renda) ou a percepção deles sobre o curso e a nota geral?

Requisitos técnicos

- **Arquitetura em camadas (medalhão): Bronze → Silver → Gold.** Bronze = dado bruto sem transformação; Silver = tipagem/tratamento de nulos (`NT_GER` vem em branco em ~15% dos registros — trate isso antes de agregar); Gold = modelo dimensional pronto para responder as 3 perguntas.
- **Python como linguagem principal da stack.**
- **Motor de execução livre** (DuckDB, Postgres, PySpark, o que preferir) — fique à vontade para escolher o que fizer mais sentido pra você, e explique sua escolha no README.
- **Alguma checagem de qualidade de dados** — fica em aberto pra você decidir o que faz sentido checar.
- **Git com histórico de commits estruturado** — queremos ver a evolução do trabalho, não um commit único.
- **Docker Compose** que suba o projeto com todas as dependências — precisamos conseguir rodar sua solução localmente com poucos comandos.

Como entregar

Monte um **dashboard** (ou outra solução, ex. IA) que a coordenação acadêmica da Unifor — sem conhecimento técnico — consiga usar sozinha para ver as respostas das 3 perguntas.

- Link de um **repositório Git público** (GitHub, GitLab, etc.).
- **README** cobrindo: como rodar (comandos exatos), arquitetura e decisões técnicas, modelo de dados da Gold, limitações conhecidas, e as respostas às 3 perguntas com link/print do dashboard.
- Quando terminar, **envie o link do repositório para o RH.**

Boa sorte, e capricha no README.